Case di Hogwarts e personalità

Nell'universo narrativo di Harry Potter gli studenti nella scuola di Hogwarts sono smistati dal Cappello Parlante, in base a presunte caratteristiche di personalità, in 4 Case: Grifondoro, Corvonero, Tassorosso e Serpeverde.
In seguito al successo della saga, oggi è possibile replicare questa assegnazione tramite un quiz online disponibile sul sito Pottermore: in questo modo i fan possono scoprire la Casa che più li rispecchia.
Il dataset utilizzato per le nostre analisi proviene da uno studio svolto dall'Università della California, che ha raccolto i dati attraverso sondaggi volontari diffusi tramite social media, contatti privati e gruppi studenteschi.
Esso contiene informazioni su 988 individui, successivamente ridotti a 847, in seguito alla selezione dei soli partecipanti maggiorenni, assegnati unicamente a una Casa e il partecipante con età superiore a 100 anni.
La nostra analisi mira a verificare la corrispondenza tra la suddivisione in Case e dei reali profili latenti di personalità ricavabili da test psicologici quali l'International Personality Item Pool (IPIP) per la misura dei Big Five (Estroversione, Coscienziosità, Gradevolezza, Stabilità Emotiva e Intelletto) e l'SD3 per la Dark Triad (Psicopatia, Narcisismo e Machiavellismo).
Ogni tratto di personalità viene misurato dall'IPIP con 10 item, ciascuno su una scala da 1 (non accurato) a 5 (molto accurato). Per quanto riguarda la Dark Triad, invece, ogni tratto viene misurato con 9 item, su una scala da 1 (molto in disaccordo) a 5 (molto d'accordo). In entrambi i casi, gli item per ciascun tratto vengono poi sommati, ottenendo un punteggio complessivo.
I punteggi di Schwartz sono stati esclusi dalla nostra analisi in quanto gli autori dimostrano che essi non contengono informazioni aggiuntive rispetto alle variabili prese in esame.
Tramite questa prima selezione, abbiamo ridotto il numero di variabili da 280 a 9.
Le etichette utilizzate fanno riferimento alla Casa desiderata (Sorting_house_wish), in quanto emerge dal paper che essa è maggiormente associata ai tratti di personalità rispetto alla Casa assegnata (Sorting_house). Questo avviene perché spesso gli individui sono portati a identificarsi nei personaggi di finzione e a rispondere alle domande del test adattando la propria autopercezione a quella della Casa in cui si rispecchiano maggiormente.

Analisi esplorativa

Abbiamo analizzato, tramite boxplot, l'andamento delle variabili per le diverse Case desiderate ed è emerso che, per molte di queste, le differenze tra gruppi sono poco evidenti e quindi potrebbero essere poco rilevanti per individuare delle differenze nette tra Case diverse.

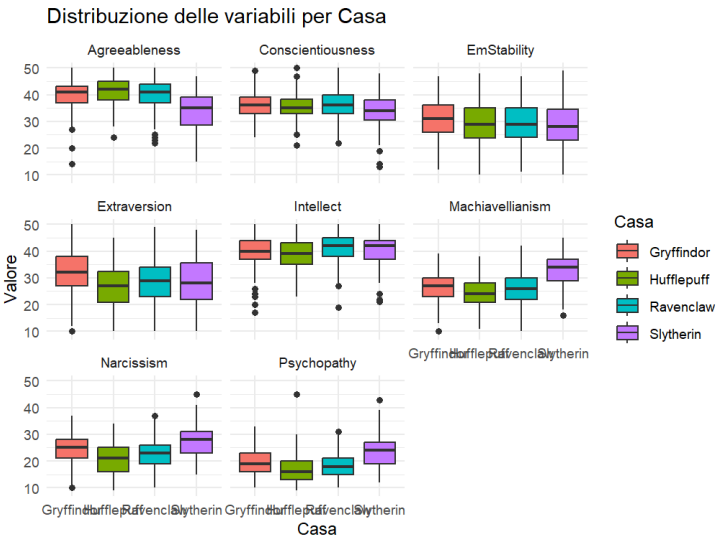

Procedendo con l'analisi delle correlazioni, abbiamo notato che alcune di esse presentano valori abbastanza elevati (Psycopathy-Machiavellianism : 0.562, Agreeableness-Psycopathy: -0.434).
Le coppie di variabili con maggior correlazione in modulo contengono informazioni ridondanti, quindi abbiamo deciso di ridurle attraverso un'analisi delle componenti principali, optando per il numero di componenti in grado di spiegare più del 70% della varianza totale.
Per una maggiore interpretabilità, abbiamo poi selezionato le variabili originali con il peso più alto rispetto alle componenti principali scelte, ovvero Psychopathy, Extraversion, EmStability e Intellect.

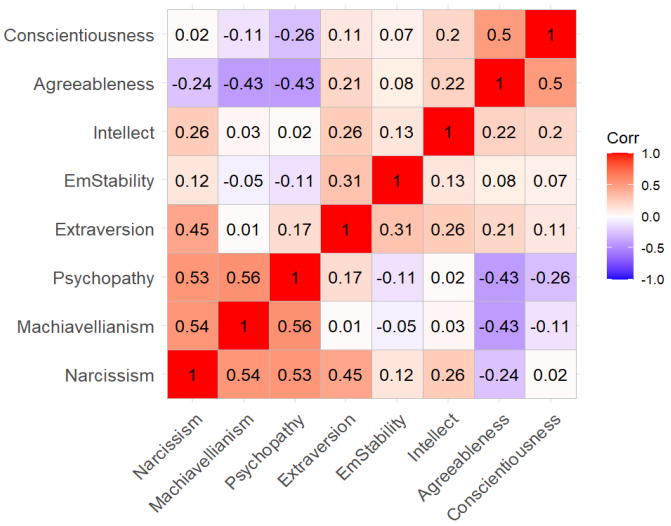

Abbiamo poi indagato la presenza di multimodalità.

Come mostrato dal grafico a destra, la densità univariata delle variabili sembrerebbe presentare diverse mode, suggerendo l'esistenza di gruppi distinti. Le correlazioni sono prossime allo 0, perciò le variabili in esame non risultano ridondanti dal punto di vista informativo. Tuttavia, dagli scatterplot non emergono gruppi ben distinti.

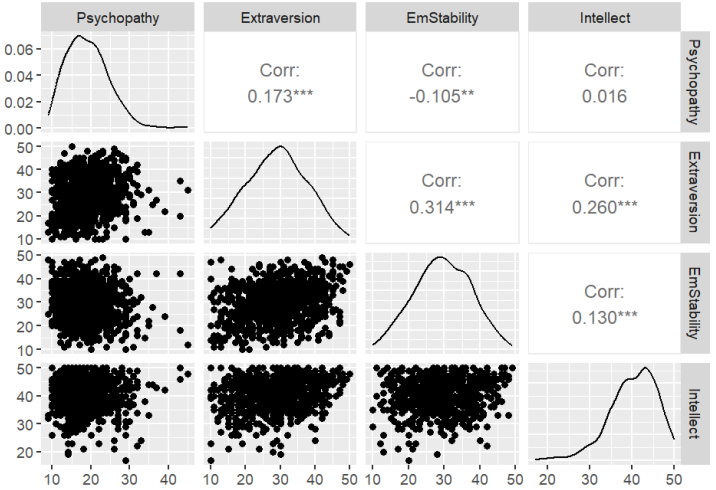

Abbiamo poi approfondito la nostra analisi esplorativa distinguendo le unità statistiche in base alla loro reale etichetta. Anche da questa rappresentazione grafica è possibile giungere alla medesima conclusione: non è possibile individuare una netta separazione tra le diverse Case sulla base delle variabili in esame.

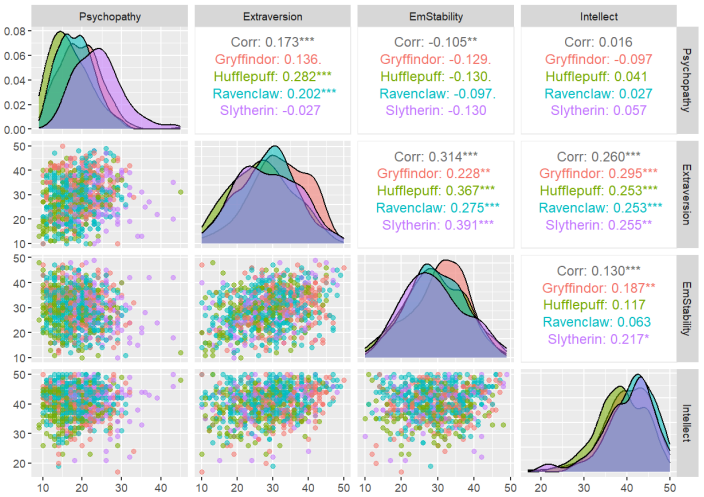

Clustering

Tramite un'analisi dei dati non supervisionata (clustering) abbiamo nuovamente indagato la presenza di gruppi eterogenei di unità statistiche.

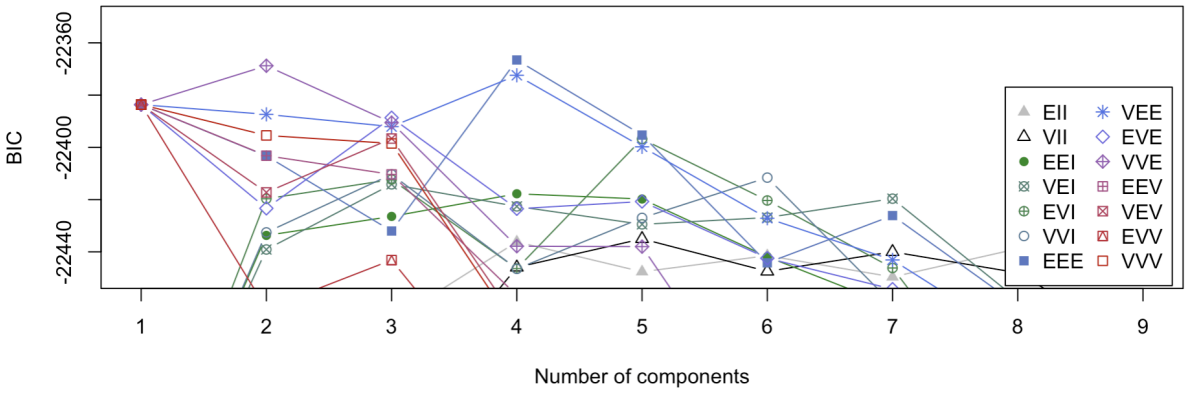

I tre migliori modelli individuati tramite selezione basata sul BIC (Bayesian Information Criterion)con il rispettivo numero di cluster sono EEE con 4 cluster, VVE con 2 cluster e VEE con 4 cluster.

Risulta, quindi, che il primo modello selezionato è quello più vincolato, in cui i cluster hanno uguale volume, forma e orientamento. I gruppi differiscono solo per i baricentri, suggerendo che le covarianze tra gruppi non presentano differenze significative.

L'entropia associata risulta 366.53: un valore piuttosto elevato, che indica una classificazione inaffidabile. L'entropia relativa risulta 0.31, confermando che le unità non sono nettamente separabili.

La selezione del modello tramite ICL (Integrated Completed Likelihood) invece individua come migliori modelli EEE con 1 cluster, EEV con 1 cluster, EVE con 1 cluster.

L'ICL penalizza il BIC rispetto al riconoscimento dei cluster da parte del modello. In questo caso, il modello non è in grado di riconoscere la divisione in gruppi.

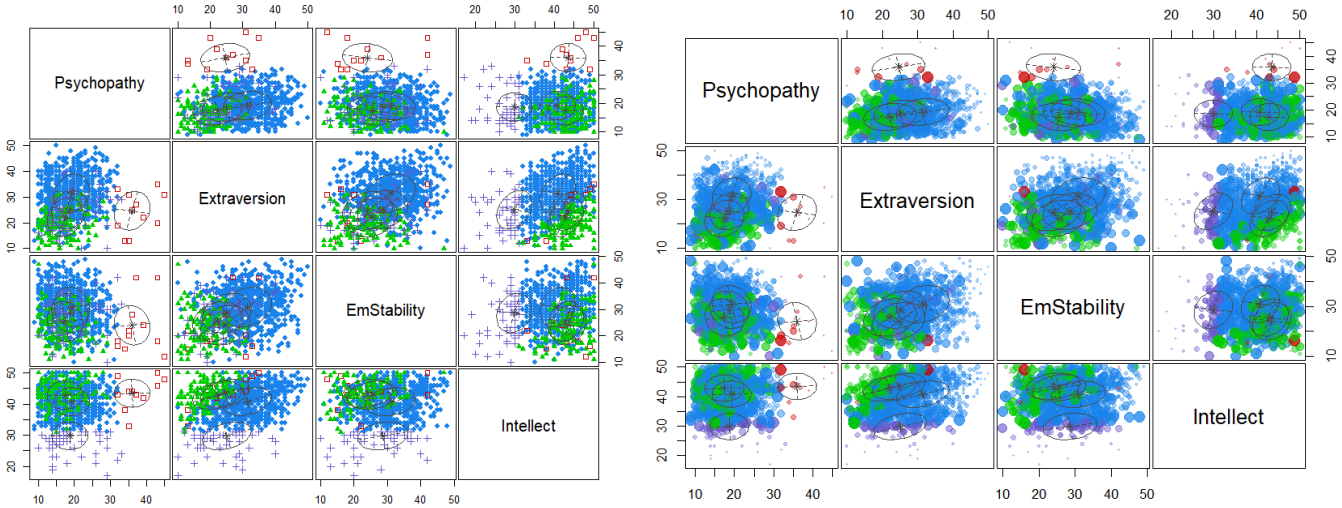

Cluster risultanti tramite selezione del modello con BIC (classificazione e incertezza)

Servendoci della reale etichettatura dei dati, possiamo calcolare la bontà del clustering effettuato.

Il CER (Classification Error Rate) assume valore di 0.579, indicando che più della metà delle unità statistiche viene classificata in modo errato.
L'ARI (Adjusted Rand Index) risulta 0.01, indicando una quasi totale indipendenza tra la reale divisione in gruppi e i gruppi ottenuti dal clustering.

Cluster \ ClasseVera	Gryffindor	Hufflepuff	Ravenclaw	Slytherin
1	175	135	266	83
2	0	1	0	10
3	15	30	63	14
4	15	18	14	8

Matrice di confusione

La matrice di confusione mostra che il modello non è in grado di riconoscere i gruppi e infatti l'accuracy è pari a 0.2916. La maggioranza dei partecipanti al test vengono assegnati al primo cluster, quasi nessuno al secondo e in piccola quantità al terzo e al quarto.

Psychopathy	Extraversion	EmStability	Intellect
19.09091	28.98229	29.55372	40.33058

Media dei valori del dataset

Il primo gruppo individuato sembra rappresentare la media campionaria delle variabili del dataset, di conseguenza è il più numeroso. Gli altri cluster invece contengono unità statistiche con caratteristiche più o meno distanti dalla media, fino a gruppi estremi (come il 2), a cui di conseguenza vengono associati meno individui.

	[,1]	[,2]	[,3]	[,4]
Psychopathy	19.23591	35.96499	17.45034	18.73754
Extraversion	31.41802	24.62378	22.15173	25.10189
EmStability	30.90292	24.03378	25.47259	28.62752
Intellect	40.81995	43.49388	42.86913	29.83987

Medie in ogni cluster

Sorting_house_wish	Psy	Extrav	Emstab	Intell
<fct>	<dbl>	<dbl>	<dbl>	<dbl>
Gryffindor	19.5	32.0	30.8	40.1
Hufflepuff	17.0	26.8	28.9	38.6
Ravenclaw	18.4	28.5	29.4	41.4
Slytherin	24.0	28.5	29	40.2

Medie nei gruppi con etichette reali

Il clustering sembra aver distinto i partecipanti in base a tratti di personalità, che tuttavia non corrispondono alla reale etichettatura, come emerge dal confronto delle medie tra i gruppi reali e quelli ottenuti tramite clustering.

Possiamo notare la discrepanza tra la classificazione reale e quella ottenuta tramite clustering evidenziando in nero le osservazioni mal classificate, che, infatti, risultano diffuse nella nuvola dei punti.

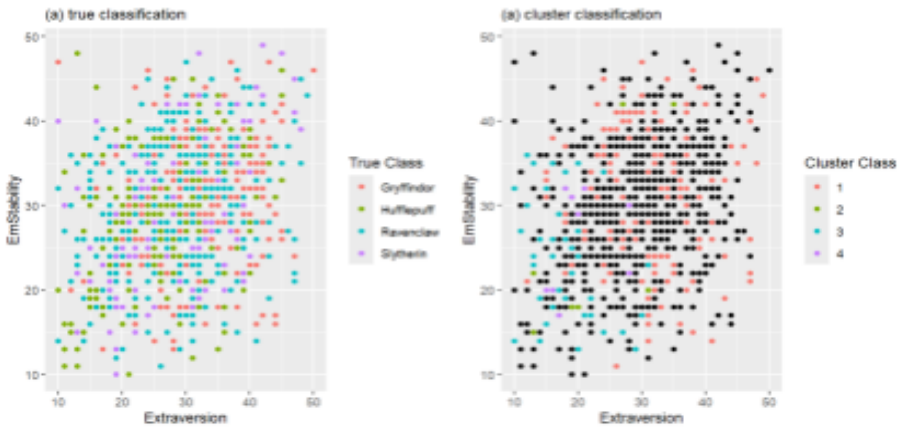

Selezioniamo la coppia EmStability - Extraversion come esempio grafico per la visualizzazione

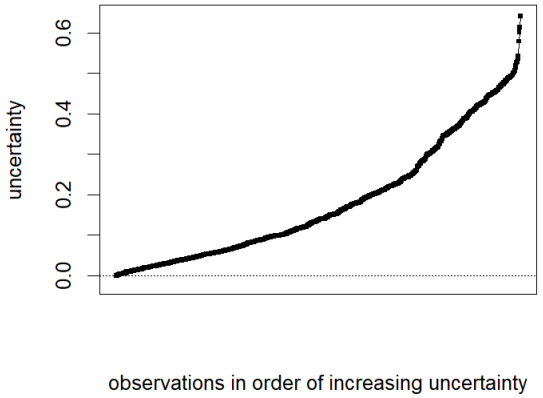

L'incertezza assume valori elevati in un numero significativo di unità statistiche.

Il confronto tra la classificazione reale e quella ottenuta tramite clustering, insieme all'analisi delle mal classificazioni e dell'incertezza, mostra che i dati non presentano una struttura naturalmente suddivisibile in quattro gruppi corrispondenti alle Case, poiché le distribuzioni e le relazioni sono molto simili e sovrapposte tra di loro.

Classificazione

Successivamente abbiamo effettuato la classificazione delle unità statistiche: tramite una tecnica supervisionata e servendoci della conoscenza delle reali etichette, abbiamo stimato un modello e lo abbiamo utilizzato per assegnare le etichette a nuove unità statistiche.
Abbiamo ripetuto le analisi più volte e con diversi numeri di blocchi per la cross validation, al fine di aumentare la robustezza del modello e togliere eventuali influenze date dall'inizializzazione casuale dei parametri.

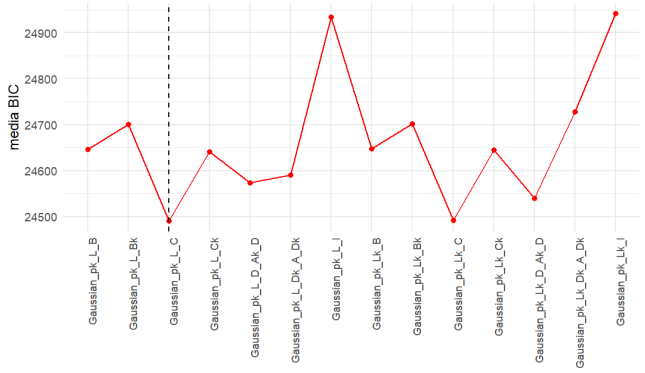

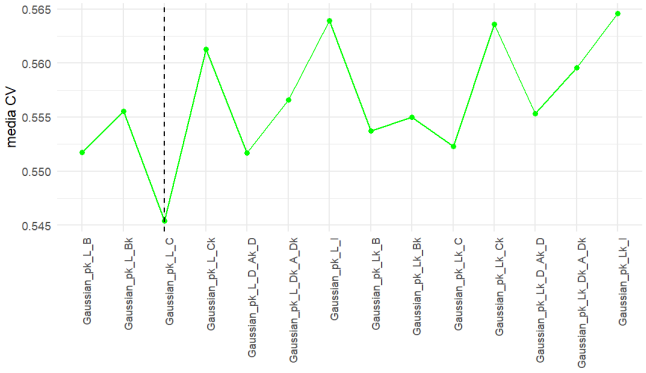

Tra tutti i modelli con mixing weights variabili tra cluster, il pk_L_C con 4 cluster a probabilità variabili, volume, forma e orientamento costanti sembra essere il più adatto a classificare le nostre osservazioni in termini sia di BIC medio sia di CV medio.
Abbiamo poi estratto un campione casuale contenente circa il 20% delle osservazioni totali da utilizzare come test set e stimato il modello sulle restanti, ottenendo un valore per l'accuracy pari a 0.4882, che mostra che il modello fatica a riconoscere le etichette reali.
Ciò è dimostrato anche dalla matrice di confusione, nella quale possiamo notare come il modello sbagli a classificare un elevato numero di unità statistiche.

	Reference			
Prediction	Gryffindor	Hufflepuff	Ravenclaw	Slytherin
Gryffindor	12	4	9	4
Hufflepuff	1	6	5	0
Ravenclaw	23	23	55	9
Slytherin	1	2	6	10

Regressione

Tramite regressione abbiamo cercato di verificare la relazione tra le Case desiderate e i tratti di personalità Psychopathy, Extraversion, Emotional Stability e Intellect. Abbiamo stimato diversi modelli mistura di regressioni multinomiali con risposta a quattro livelli, uno per ciascuna casa.

L'obiettivo è capire come i tratti analizzati influenzano la probabilità di appartenenza a ciascuna casa, ipotizzando l'esistenza di diversi gruppi latenti nella popolazione con diversa relazione tra risposta e covariate. Nel modello stimato, ogni componente della mistura rappresenterebbe una diversa relazione tra risposta e covariate.

Sono stati stimati modelli con un numero di componenti della mistura da 1 a 4, valutando l'esistenza di gruppi latenti in cui i tratti influenzano la Casa. Dato l'elevato numero di parametri da stimare mantenendo tutte e quattro le variabili, abbiamo utilizzato una procedura di selezione backward sul modello multinomiale completo che ci ha portato ad escludere la variabile Emotional Stability.

Abbiamo valutato l'ICL stimato per ogni modello, osservando che il minimo in valore assoluto corrisponde al modello con una sola componente. Risulta quindi che il modello supportato dai dati è il multinomiale classico. Alcuni tratti di personalità influenzano significativamente le probabilità relative di appartenenza alle Case rispetto alla baseline (Gryffindor): un aumento di Intellect è associato a un incremento degli odds di essere assegnati a Ravenclaw, mentre un aumento di Psychopathy è associato a un incremento degli odds di essere assegnati a Slytherin. Al contrario, valori più elevati di Extraversion tendono a ridurre gli odds di essere assegnati alle altre Case rispetto a Gryffindor.

Tuttavia, l'analisi con modelli a classi latenti non ha identificato sottogruppi di individui con diversi pattern di associazione, suggerendo la mancanza di effetti significativi tali da evidenziare una distinzione netta.

Conclusioni

Attraverso l'analisi dei modelli mistura, siamo giunte alla conclusione che i criteri individuati da J.K.Rowling per suddividere gli studenti di Hogwarts in Case non corrispondono a profili latenti di personalità realmente individuabili tramite test psicologici.

Non è emersa una corrispondenza significativa tra i profili osservati nel campione e la Casa desiderata da ciascun individuo. Le differenze nei tratti di personalità tra le Case sono limitate, sovrapposte e non sufficienti ad individuare profili psicologici distinti e specifici, come mostrato dai bassi valori dell'accuratezza dei modelli di clustering e classificazione.

I tratti di personalità descrivono le caratteristiche e i comportamenti dei singoli individui e non riflettono una rigida classificazione in categorie: infatti, possono condividere tratti di personalità senza necessariamente appartenere ad una casa specifica.